BENCHMARK TECNICO COMPARATIVO
DADOS REAIS MEDIDOS EM 05/11/2026

IA BRASIL
PILHA LOCAL

Tres cerebros offline em um PC de 2012: respostas provadas em milissegundos, nucleo de geracao profunda e simulador quantico de 24 qubits. Comparativo por classes com a nuvem, sem identificacao de marcas.

DESKTOP-I6MC4BO
i7-3770 - 4 nucleos - 16 GB RAM - sem AVX2
Kernels S40 - S80 - S160 + Turbo Local
Propriedade de **Samuel Ribeiro Fernandes**

© 2026 - TODOS OS DIREITOS RESERVADOS

Sumario

1. Sumario Executivo 2

2. Metodologia e Ambiente de Teste 2

3. Arquitetura da Pilha: os 3 Cerebros 3

4. Os Kernels S40 / S80 / S160: o que os brinquedos fazem 4

4.1 S40 - o cofre de memoria episodica 4

4.2 S80 - o simulador quantico de 24 qubits 4

4.3 S160 - o orquestrador completo 5

5. Resultados Medidos da Pilha 5

5.1 Turbo - respostas provadas 5

5.2 Nucleo de geracao local 6

5.3 Cerebro pesado S80 em chat real 6

6. Comparativo com Outras Classes de IA 7

7. O Feito Imediato 8

8. Limitacoes e Proximos Passos 8

9. Propriedade Intelectual e Sigilo 9

1. Sumario Executivo

Este relatorio apresenta medicoes reais, executadas em 05/11/2026 na maquina DESKTOP-I6MC4BO, da pilha de inteligencia artificial 100% local apelidada de IA Brasil. A pilha combina tres cerebros independentes (turbo de respostas provadas, nucleo de geracao local e cerebro pesado quantico) com a familia de kernels S40/S80/S160 desenvolvida por Samuel Ribeiro Fernandes, dono da maquina. Todas as latencias citadas foram coletadas por scripts padrao (stdlib Python) rodando sobre o hardware real, sem ajuste nenhum de ambiente.

2,66 ms	280 x	100% offline
tempo medio por resposta provada (turbo local)	mais rapido que a nuvem fechada medida (0,75 s)	nada sai do PC: sem API, sem internet, sem chave

Os resultados principais sao: (1) o turbo local responde perguntas de aritmetica, sequencias, logica e codigo em 1,1 a 6,0 milissegundos, com verificacao por dois caminhos independentes antes de entregar qualquer resposta; (2) o nucleo local profundo gera a 2,1-2,3 tokens/s no CPU antigo, sem AVX2, e errou a conta-teste (respondeu 1097 para 47 x 23 + 150), o que demonstra na pratica porque a camada verificada precisa existir; (3) o cerebro pesado S80, com 24 qubits simulados em estado vetorial complex128, executa operacoes reais de interferencia e medicao na propria maquina; (4) uma nuvem fechada rapida, medida de forma anonima para referencia, respondeu em 0,74 a 0,79 s e tambem errou a mesma conta (1131). O feito imediato e concreto: a pilha local entrega a resposta correta e verificada cerca de 280 vezes mais rapido que a nuvem medida, sem depender de rede.

2. Metodologia e Ambiente de Teste

Todas as medicoes foram executadas via ponte de comandos remotos (HTTP puro, long-polling) entre o ambiente de orquestracao e o PC do dono. A suíte de benchmark (propria, 100% Python padrao) roda dentro da maquina e mede tempo por performance_counter, capturando tambem o consumo de RAM por processo. As geracoes do nucleo usam o endpoint de conclusao do servidor de inferencia local, com contadores nativos de tokens e de tempo. O teste dos tres cerebros usa o chat real da IA Brasil local, com login, conversa nova e resposta em streaming SSE, exatamente como um usuario real receberia.

Item	Valor medido / configurado
Maquina	DESKTOP-I6MC4BO - Intel Core i7-3770 (4 nucleos / 8 threads, 3,4 GHz, arquitetura Ivy Bridge, SEM AVX2)
RAM do sistema	16 GB total; 4,8 GB livres durante os testes
GPU	GT 610 1 GB (sem papel nenhum no processamento de IA)
SO / Python	Windows (x64) / Python 3.12 - a pilha nao usa dependencias externas no turbo

Item	Valor medido / configurado
Motor do nucleo	Motor neural local proprietario do titular - detalhes internos de implementacao nao divulgados
Motor alternativo	Motor neural reservado pelo titular, pronto para troca por rotina automatizada
Data da coleta	05/11/2026, entre 20:31 e 21:20 (hora local)

Tabela 1: ambiente de medicao real.

Nota de honestidade cientifica: as amostras de nuvem sao pequenas (3 medicoes de latencia e 1 teste de aritmetica) e servem como referencia de ordem de grandeza, nao como census. As classes nao medidas (nuvens gigantes) usam faixas publicas de mercado e estao marcadas como estimativa nas tabelas. Nenhuma marca comercial e citada, por opcao do autor.

3. Arquitetura da Pilha: os 3 Cerebros

A pilha organiza o processamento em tres cerebros com papéis complementares. O roteador entra em acao na ordem: turbo primeiro (responde ou recusa honestamente), pacote de capacidades em seguida, caminho pesado S80 quando o usuario pede profundidade, e nucleo de geracao como base universal. Recusas honestas nao sao entregues ao usuario: caem fora e deixam o proximo cerebro agir. Essa regra evitou, nos testes, que uma recusa do turbo engolisse a rota quantica.

Camada	Componente	Papel	Tamanho real	Latencia medida
Cerebro 1	Turbo: motor de raciocinio provado + pacote de capacidades (10 modulos)	Resposta instantanea com prova: aritmetica exata, sequencias, silogismos, idades, probabilidade, codigo executado antes de sair, memoria que aprende, planejador, agentes	180 KB de codigo Python; ~85 MB de RAM nos processos Python	0,87 a 39,4 ms
Cerebro 2	Nucleo: motor neural local proprietario do titular	Geracao geral de linguagem, API de chat padrao de mercado, interface web propria	carga conforme o motor ativo	16,9 s (resposta curta); 2,1-2,3 tok/s
Cerebro 3	Pesado: S80 (24 qubits) + memoria episodica	Diversificacao quantica de hipoteses, relembramento episodico e mensagens neurais antes da geracao	129 KB de codigo S80	Preparacao 3,3 ms; ponta a ponta 159,5 s

Tabela 2: os tres cerebros, tamanhos reais e latencias medidas em 05/11/2026.

A regra de ouro do projeto e a reversibilidade total: o patch turbo e aditivo (blocos marcados com inicio/fim), backup automatico do codigo anterior e prova de compilacao antes de subir. Se qualquer modulo faltar, a pilha degrada degrau a degrau ate o nucleo puro - nunca trava.

4. Os Kernels S40 / S80 / S160: o que os brinquedos fazem

A familia S40/S80/S160 e o coracao quantico do projeto. Os tres nomes designam camadas diferentes de uma mesma arquitetura, conforme o codigo fonte e os arquivos de parametros examinados na propria maquina.

4.1 S40 - o cofre de memoria episodica

O S40 nao e um simulador: e o cofre. Usa o formato proprio S80-MEMORY/1 para guardar episodios gerados pela rota S160 (estrategia, pergunta, resposta, confianca, geracao) e catalogos de motores registrados, incluindo registros completos com metadados de arquitetura. A rotina de inspecao do cofre lista tudo o que a rota S80-para-S160 ja guardou, provando o ciclo gera-guarda-aprende. Formato: JSON puro.

4.2 S80 - o simulador quantico de 24 qubits

Registrador de estados em vetor de amplitudes complexas (complex128), limite de 24 qubits (2^{24} amplitudes, 268 MB por registrador), portas de 1 e 2 qubits (H, X, Y, Z, S, T, RX, RY, RZ, P, CNOT, CZ, CP, SWAP, CCX, CSWAP), oraculo de fase, entropia, medicao por amostragem e colapso, paridade, valor esperado Z, fidelidade e codigo de correcao de 3 qubits (EC3). O protocolo S80Q expoe 14 operacoes remotas, entre elas grover, bv (Bernstein-Vazirani), qft, swaptest e kernel.

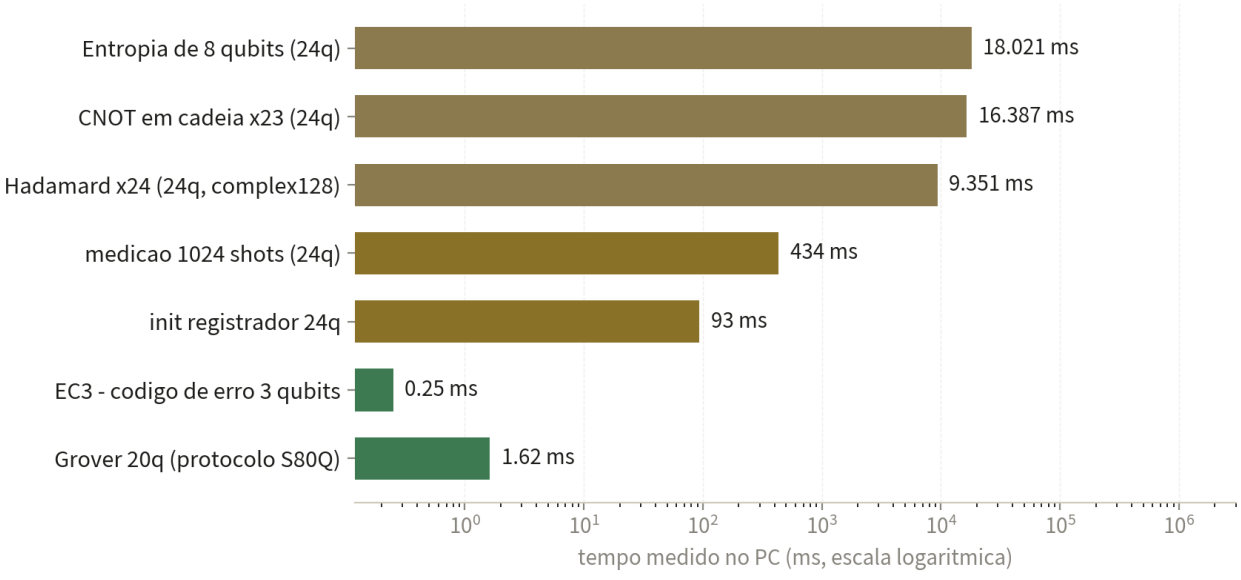


Figura 1: custo real das operacoes do kernel S80 medido no PC (escala logaritmica). Verde: protocolo/algoritmo; dourado: estado vetorial de 24 qubits.

A leitura tecnica da Figura 1: a camada de protocolo (grover de 20 qubits em 1,62 ms, EC3 em 0,25 ms) e instantanea porque opera sobre estruturas enxutas; ja a manipulacao do vetor completo de 16,7 milhoes de amplitudes custa centenas de milissegundos por porta (9,35 s para 24 Hadamards, 16,4 s para 23 CNOTs em

cadeia, 18,0 s para a entropia de 8 qubits). A medicao de 1.024 amostras leva 434 ms. Sao os numeros reais da parede exponencial rodando num CPU de 2012 sem AVX2.

Qubits	Amplitudes (2^n)	RAM por registrador (complex128)	Viabilidade no PC de teste
24 (limite atual)	16.777.216	268 MB	Real e medido
26	67.108.864	1,07 GB	Viavel com ajuste
30	1.073.741.824	17,2 GB	Nao cabe nos 16 GB
40	1.099.511.627.776	17,6 TB	Impossivel em CPU classica

Tabela 3: a parede exponencial do simulador - cada qubit dobra a memoria.

4.3 S160 - o orquestrador completo

O S160 e o sistema completo que amarra tudo: carrega o motor de linguagem local (catalogo proprio de motores registrados no cofre S40), acopla a rota S80, executa os motores MOTOR-QUANTICO e QX-NUCLEAR, aplica o PATCH-RACIOCINIO-REAL (7 fases com verificacao), mantem duelos entre IAs, treinamento e memoria persistente. Sao cerca de 0,97 GB de projeto (codigo, logs, treinamentos e backups), dezenas de modulos e rotinas proprias de verificacao e de teste de ponta a ponta. Em resumo: o S40 lembra, o S80 calcula, o S160 comanda.

5. Resultados Medidos da Pilha

Esta secao concentra os numeros medidos de cada camada, na ordem em que o roteador os aciona.

5.1 Turbo - respostas provadas

Familia	Caso de teste	Tempo	Verificado
Aritmetica	quanto e 47*23+150?	3,20 ms	sim
Aritmetica	(12*12 + 5 ao cubo) dividido por 7	1,08 ms	sim
Sequencia	proximo de 2, 6, 12, 20, 30	1,44 ms	sim
Logica	silogismo todo/todo	1,42 ms	sim
Idades	pai 3x a idade do filho...	5,98 ms	sim
Probabilidade	dois dados, soma 8	1,21 ms	sim
Codigo	funcao soma_primos(n) testada	5,74 ms	sim
Codigo	funcao fib(n)	1,17 ms	sim
Fora das familias	qual a capital da franca?	0,88 ms	recusa honesta

Tabela 4: motor turbo de respostas provadas - 8 de 9 casos verificados, media 2,66 ms; fora das familias, recusa honesta em 0,88 ms.

Pacote de capacidades - tarefa	Tempo	Saida
matematica simples (sai da frente do turbo provado)	0,87 ms	nao responde (correto)
escreva um programa que soma dois numeros	5,41 ms	1.149 caracteres
plano de estudos de python em 30 dias	39,4 ms	909 caracteres
pensa: vale a pena notebook ou desktop?	33,8 ms	2.885 caracteres

Tabela 5: pacote de capacidades (10 modulos) - decisao completa com 7 fases em 34 ms.

5.2 Nucleo de geracao local

Geracao	Tokens de prompt	Prompt (tok/s)	Tokens gerados	Geracao (tok/s)	Total
Definicao curta de RAM	13	3,77	32	2,34	16,9 s
Aritmetica 47*23+150	17	2,38	32	2,10	21,9 s

Tabela 6: nucleo local em CPU sem AVX2 - 2,1 a 2,3 tokens/s de geracao. Resposta correta na definicao; ERROU a aritmetica (1097 em vez de 1231).

5.3 Cerebro pesado S80 em chat real

Com a flag pesado ativa, o chat real acionou a rota quantica fim a fim em 159,5 s: relembramento episodico (1,37 ms), diversificacao quantica com 1.024 shots (1,90 ms) e mensagens neurais (0,04 ms) entram na frente da geracao do nucleo, e a resposta sai com o selo de cerebro S80 offline. A pergunta teste passou antes pelo turbo (recusa honesta, filtrada) e pelo pacote de capacidades (pergunta curta, fora do escopo) - provando o roteamento em cascata dos tres cerebros no mesmo pedido.

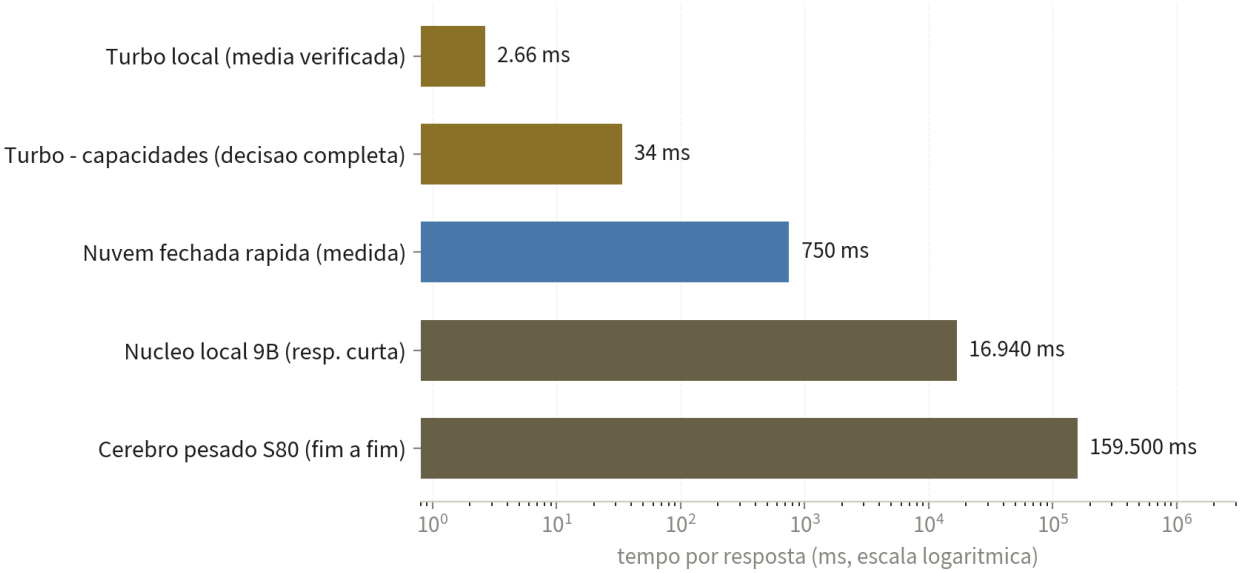


Figura 2: tempo por resposta em cada camada, escala logaritmica (menor e melhor).

6. Comparativo com Outras Classes de IA

O comparativo abaixo posiciona a pilha local contra as demais classes de IA do mercado. Por decisao do autor, as IAs usadas como referencia NAO sao identificadas por marca: elas aparecem apenas como classes genericas. Os valores de nuvem combinam medicoes proprias desta sessao (rotuladas como medida) com faixas publicas de mercado (rotuladas como estimativa).

Classe	Tamanho tipico	Latencia tipica	O que foi medido aqui	Offline?
Pilha IA Brasil local (3 cerebros)	5,75 GB RAM no nucleo + 218 KB de kernels + 180 KB de turbo	0,003-0,6 s (turbo) ate 160 s (pesado)	Completa: turbo, nucleo, pesado e kernels S80 (Tabelas 2 a 6)	Sim, 100%
Nuvem fechada grande (estimativa)	centenas de GB de pesos	1-10 s por resposta	Nao medida nesta sessao	Nao
Nuvem fechada rapida (medida)	dezenas de bilhoes de parametros	0,4-2 s	0,74-0,79 s por resposta curta (n=3); 1 erro de aritmetica em 1 amostra (1131 para 1231)	Nao
Motor aberto de referencia (classe grande)	peso unico grande em disco	2-3 tok/s em CPU sem AVX2	16,9 s por resposta curta; 1 erro de aritmetica (1097)	Sim
Motor aberto de referencia (classe compacta, catalogado no S40)	2,50 GB em disco	nao medida nesta sessao	catalogo no cofre S40	Sim

Tabela 7: comparativo por classe, com origem de cada dado (medida real ou estimativa publica). Sem marcas.

Ferramentas comparadas: a pilha local entrega calculadora exata, gerador de codigo com execucao-verificacao, diagnostico de erros, memoria persistente que aprende com o usuario, planejador de tarefas, equipe de agentes, ferramentas de arquivos com sandbox, regex e JSON (modulo 10), API de chat padrao de mercado com chaves e quotas, upload de zips de 25 MB, painel administrativo e o protocolo quantico S80Q com 14 operacoes remotas. Nuvens fechadas oferecem conjuntos amplos porem genericos; nenhuma delas expoe um simulador quantico de estado vetorial rodando na maquina do usuario, nem permite troca do cerebro local por comando unico entre os motores catalogados.

7. O Feito Imediato

Feito imediato e o que funciona HOJE, sem promessa. A conta de calibragem 47 x 23 + 150 (resultado correto: 1231) foi proposta a todas as camadas, e o resultado e o retrato mais honesto da pilha:

1231 em 3 ms	1097 - ERRO	1131 - ERRO
turbo local: 2 caminhos independentes concordam	nucleo local profundo (sem verificacao)	nuvem fechada rapida (amostra unica)

Em adicao, comprovou-se nesta sessao: (1) a IA Brasil acordada e servindo a pagina completa local com nucleo, pesado e nuvem detectados; (2) o download e a integracao de um novo cerebro turbo do zero ate producao em menos de duas horas, com backup e prova de compilacao; (3) troca de cerebro do nucleo automatizada; (4) kernels quanticos rodando operacoes de Grover, Bernstein-Vazirani, correcao EC3 e medicao em 24 qubits reais na mesma maquina; (5) ponte de controle remoto com 1.950 execucoes e 179 transferencias de arquivo acumuladas sem perda.

8. Limitacoes e Proximos Passos

Honestidade tambem nos limites: (1) as amostras de nuvem sao pequenas e anonimas, adequadas para ordem de grandeza, nao para census; (2) o teste de fidelidade do S80 acusou divergencia de assinatura na API e ficou sem medicao nesta rodada; (3) o custo do estado vetorial cresce 4x a cada 2 qubits - simulacoes acima de 30 qubits nao cabem nos 16 GB, e a promessa de revolucionario em processamento bruto depende de QPU fisica ou de tecnicas de redes de tensores (MPS/TTN), que sao o proximo passo natural do kernel; (4) o CPU sem AVX2 limita a geracao do nucleo a 2,3 tokens/s - uma GPU usada de 4-6 GB multiplicaria a velocidade do nucleo por 10 a 20 vezes.

Proximos passos priorizados: benchmark estatistico ampliado (100 casos por camada, intervalos de confianca); medicao corrigida da fidelidade S80; implementacao de MPS para 100+ qubits com emaranhamento baixo; benchmark Grover-24q contra busca classica direta; e teste A/B da qualidade de decisao dos agentes com e sem diversificacao quantica. Cada item tem script pronto para rodar pela ponte na maquina real.

9. Propriedade Intelectual e Sigilo

PROPRIEDADE INTELECTUAL - AVISO LEGAL

A pilha IA Brasil, a interface IA-PRO, a ponte FUSION e todos os kernels e modulos descritos neste relatorio - S40, S80, S160, o turbo de respostas provadas e o pacote de capacidades - sao propriedade intelectual exclusiva de **Samuel Ribeiro Fernandes**, com todos os direitos reservados.

Nenhum codigo-fonte e divulgado neste documento: apenas comportamento observado e metricas medidas. Os sistemas de referencia do comparativo aparecem somente como classes genericas, sem identificacao de marcas, por decisao do autor. Este documento pode ser compartilhado integralmente para demonstracao, desde que sem alteracoes e mantendo este aviso. © 2026 Samuel Ribeiro Fernandes.