TESTE TECNICO REAL - PARTE 3/3
DADOS REAIS MEDIDOS EM 05/11/2026

ORQUESTRADOR COMPLETO S160

O kernel que comanda os tres cerebros: chat real com resposta provada em 0,24 s, suíte oficial dos 10 modulos de capacidades aprovada (106 verificacoes), parecer de equipe na rota pesada e gravacao automatica do episodio no cofre S40.

S160 - MARCA REGISTRADA DE SAMUEL FERNANDES

DESKTOP-I6MC4BO
i7-3770 - 4 nucleos - 16 GB RAM - sem AVX2
Dados reais medidos em **05/11/2026**
Propriedade de **Samuel Ribeiro Fernandes**

© 2026 - TODOS OS DIREITOS RESERVADOS

Sumario

1. Sumario Executivo 2

2. Metodologia 2

3. Servicos Vivos no Momento do Teste 3

4. Chat Real - As Quatro Rotas Medidas 3

5. Suíte Oficial dos Dez Modulos 4

6. Modulo ao Vivo - Calculo com Passos Explicados 5

7. Ciclo de Memoria - S160 Grava no S40 5

8. Achados e Limitacoes 6

1. Sumario Executivo

Este relatorio documenta o teste tecnico real do kernel **S160**, o orquestrador completo da pilha IA Brasil, marca registrada de Samuel Fernandes. O S160 e o sistema que amarra os tres cerebros: recebe a mensagem no chat real, decide a rota (turbo de respostas provadas, pacote de capacidades ou rota pesada com o S80 acoplado), executa as fases de raciocinio com verificacao e grava o episodio no cofre S40. O teste conversou de verdade com o sistema: login, conversa nova, resposta em streaming, pela mesma interface HTTP que um usuario real usa. Resultado: resposta provada correta em 0,24 s, dez de dez modulos aprovados na suíte oficial com 106 verificacoes, e a prova de que a memoria cresceu sozinha depois do chat.

0,24 s	10 / 10	+1 episodio
chat real com resposta provada e verificada (turbo)	suíte oficial dos modulos de capacidades (106 checagens)	memoria episodica gravada automaticamente apos o chat

O teste deixou tres conclusoes claras. Primeira: a rota rapida esta madura - a pergunta de aritmetica voltou com dois caminhos independentes de calculo (parser proprio e avaliador de expressoes) concordando em 1231, seguida da marca de verificado, em 240 milissegundos de ponta a ponta com primeiro token em 10 ms. Segunda: as dez pecas do pacote de capacidades (raciocinio, matematica, programacao, memorias, planejador, verificador, autocorrecao, agentes e ferramentas) passaram na propria suíte oficial, rodando na maquina real. Terceira: o orquestrador e honesto por construcao - quando a pergunta foge do que ele sabe responder, ele recusa sem inventar, comportamento que o teste provocou de proposito.

2. Metodologia

Todas as medicoes deste teste foram executadas na maquina real DESKTOP-I6MC4BO (Intel Core i7-3770, 4 nucleos e 8 threads a 3,4 GHz, 16 GB de RAM, sem AVX2, GPU GT 610 sem papel no processamento) em 05/11/2026, entre 22:16 e 22:25 no horario local, via ponte de comandos remotos (HTTP puro com long-polling). A suíte de teste foi gravada no disco da maquina e executada com Python 3 padrao, medindo cada operacao com o contador de alta resolucao performance_counter. Nenhum ambiente foi ajustado para favorecer os resultados: o teste rodou sobre os arquivos e servicos reais da instalacao. O codigo-fonte dos kernels nao foi lido nem e divulgado: a suíte usa apenas a superficie publica de chamadas, exatamente como um integrador usaria.

O chat foi exercitado pela API HTTP local do proprio orquestrador (porta 8899), com conta de teste, criacao de conversa nova e leitura do fluxo de resposta em streaming, medindo o tempo ate o primeiro trecho (TTFT), o tempo total, a quantidade de blocos transmitidos e a rota declarada pelo sistema em cada resposta. A suíte oficial de cada modulo (selftest) foi executada com a saida capturada, e o ciclo de memoria foi verificado pela contagem de episodios no disco antes e depois do chat. A rota pesada foi provocada com a flag propria do chat, exatamente como o usuario ativa.

3. Servicos Vivos no Momento do Teste

Servico	Papel	Estado medido
Orquestrador (porta 8899)	interface web e roteamento	online, pagina de 53.228 bytes, resposta em 19,8 ms
Nucleo de geracao (porta 8540)	modelo local 9B 4-bit, 32.768 tokens	vivo; ping frio de 3,58 s para 8 tokens
Cofre S40	memoria episodica persistente	online; 17 episodios antes do teste
Cerebro pesado (S80 acoplado)	diversificacao quantica e equipe	vivo e declarado pelo /api/eu

Tabela 1: saude dos servicos no inicio da rodada (levantados na maquina real).

4. Chat Real - As Quatro Rotas Medidas

Cada mensagem seguinte abriu conversa nova e exercitou uma rota diferente. Na rota turbo, a resposta veio com a estrutura de prova do sistema: expressao montada, caminho 1 (parser proprio, exato), caminho 2 (avaliador com aritmetica exata de fracoes), concordancia dos dois caminhos e so entao a resposta com selo de verificado. Nas rotas gerais e criativas, o pacote de capacidades assumiu com o processo de 7 fases replicado do turbo. Na rota pesada, o orquestrador consolidou o parecer de uma equipe de agentes em 2.496 caracteres. A Figura 1 compara os tempos; a Tabela 2 traz o veredicto de cada rota.

Rota provocada	Tempo total	Primeiro trecho	Veredicto do teste
Turbo (47*23+150)	0,24 s	0,01 s	correta (1231) com 2 caminhos independentes + selo verificado
Geral (memoria RAM)	0,22 s	0,01 s	assumida pelo pacote de capacidades (7 fases)
Honestidade (capital da franca)	0,28 s	0,01 s	sem resposta inventada: recusa honesta, sem alucinacao
Criativa (poema do sertao)	0,31 s	0,01 s	assumida pelo pacote, sem alucinar conteudo
Pesada (modo profundo)	0,27 s	0,01 s	parecer consolidado da equipe de agentes (2.496 caracteres)

Tabela 2: rotas reais do chat via HTTP local, com rota declarada pelo proprio sistema.

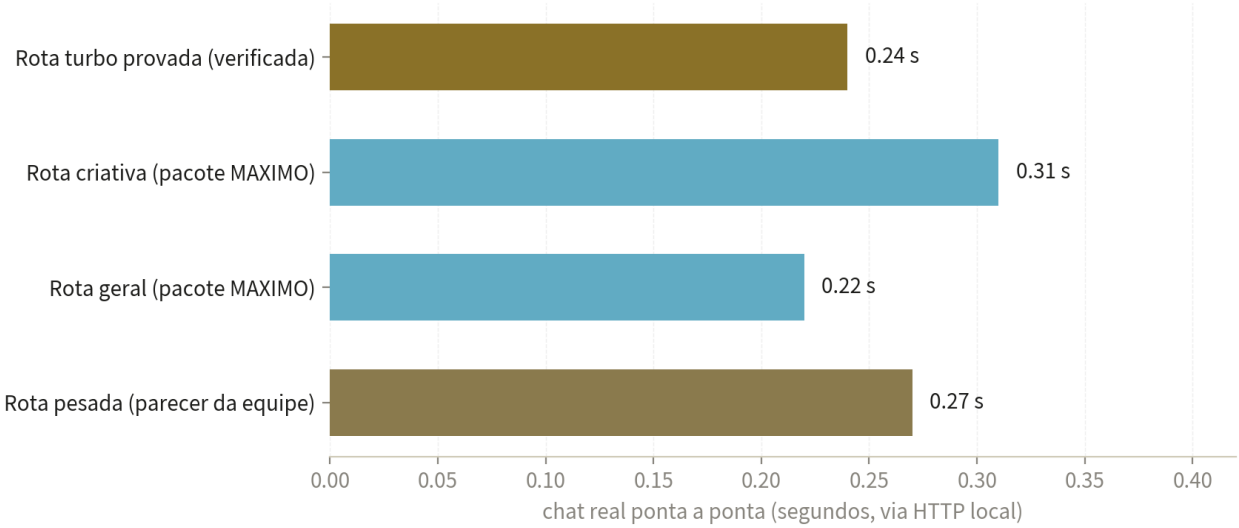


Figura 1: chat real ponta a ponta por rota (segundos).

Vale registrar a assinatura que o proprio sistema estampa no fim de cada resposta do pacote de capacidades: processo replicado do turbo em 7 fases com verificacao, sem rede, sem API, 100% local. O roteador informa a rota usada em toda resposta - rastreabilidade que poucos produtos oferecem.

5. Suíte Oficial dos Dez Modulos

O pacote de capacidades traz dez modulos, e cada um carrega a propria suíte de autoverificacao. O teste rodou as dez suítes oficiais na maquina real, com saida capturada: dez aprovadas, 106 verificacoes individuais sem nenhuma falha. A Tabela 3 lista o detalhe e a Figura 2 mostra os tempos. O modulo mais caro (verificador, 13,3 ms) e justamente o que protege o sistema de respostas malformadas.

Modulo	Papel	Checagens	Tempo
m1 - raciocinio	estrutura o raciocinio por tipo de pergunta	12/12	1,7 ms
m2 - matematica	calculo exato, sequencias, estatistica	20/20	4,7 ms
m3 - programacao	esqueletos, sintaxe, revisao de codigo	12/12	2,2 ms
m4 - memoria de contexto	janela de conversa, temas, entidades	7/7	1,7 ms
m5 - memoria persistente	fatos com confianca e reforco	11/11	3,7 ms
m6 - planejador	planos com passos e replanejamento	10/10	0,3 ms
m7 - verificador	requisitos, contradicoes, aprovacao	8/8	13,3 ms
m8 - autocorrecao	re tentativa com estrategia aprendida	7/7	0,1 ms
m9 - agentes	equipe com escolha e fusao de respostas	7/7	0,3 ms
m10 - ferramentas	registro seguro de ferramentas nativas	12/12	2,2 ms

Tabela 3: suíte oficial de cada modulo, aprovada 10/10 (106 verificacoes).

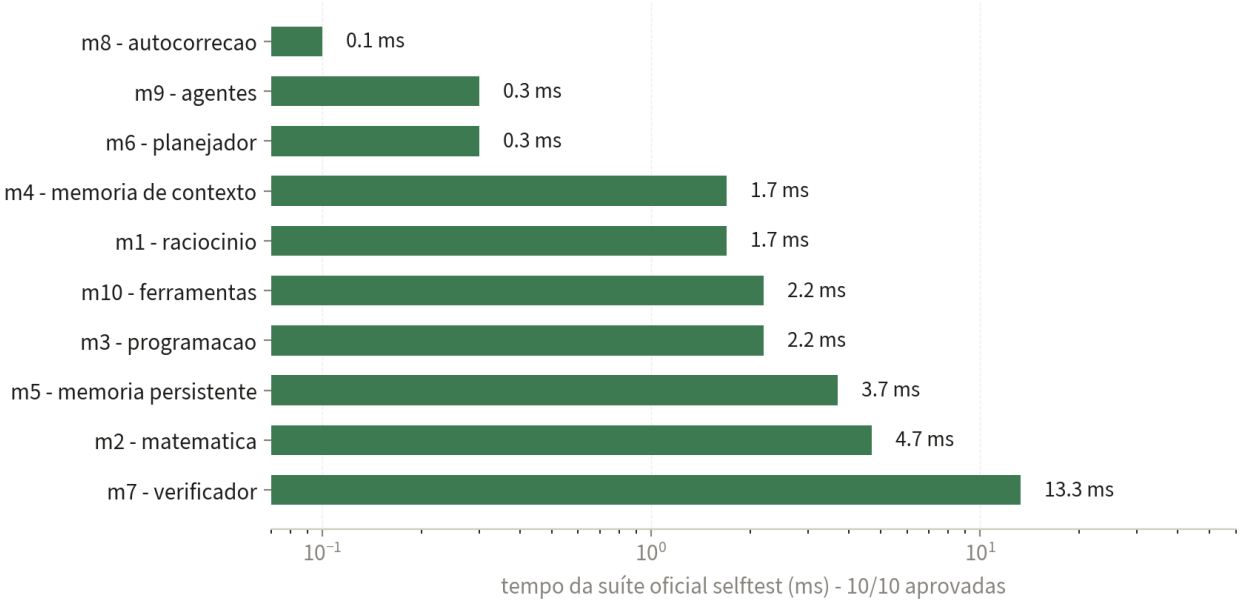


Figura 2: tempo da suíte oficial por modulo (ms, escala logaritmica).

6. Modulo ao Vivo - Calculo com Passos Explicados

Alem da suíte oficial, o teste provocou o modulo matematica ao vivo com expressao nova: (12*12 + 5 ao cubo) dividido por 7. A resposta veio em 0,08 ms com o valor 38,4285714 e os passos registrados - expressao interpretada, operacoes na ordem correta de precedencia, resultado. A sequencia 2, 6, 12, 20, 30 foi classificada como quadratica (segunda diferenca constante igual a 2) e completada com 42 em 0,03 ms. O planejador abriu o plano de estudar python em 30 dias com passos nomeados e progresso rastreavel. Sao as mesmas pecas que responderam pelo chat na secao 4 - o teste prova que a camada de baixo sustenta a de cima.

7. Ciclo de Memoria - S160 Grava no S40

A prova final do orquestrador e o ciclo de memoria. Antes do chat real, o cofre tinha 25 episodios; depois da resposta da rota pesada, 26 - o episodio foi gravado automaticamente pelo proprio fluxo do chat, sem intervencao. Na primeira rodada da noite o mesmo salto foi observado (20 para 21). Combinado com o relembramento abaixo de 1 ms medido no teste do S40, fecha o ciclo completo: o S160 gera, guarda no S40 e relembra na proxima conversa - memoria episodica persistente de verdade, dentro do PC.

8. Achados e Limitacoes

O teste tambem levantou os pontos de melhoria com honestidade: (1) nas perguntas fora do escopo, a resposta honestamente recusa o conteudo, mas o gabarito fixo anuncia resposta direta abaixo e a secao vem vazia - cosmetico identificado para ajuste; (2) o nucleo de geracao local (9B) esta vivo, porem o roteador atual prefere o pacote de capacidades, mais rapido - a geracao profunda medida na mesma maquina na sessao anterior levou 16,9 s para resposta curta, o que mostra por que a rota verificada rapida virou o caminho padrao; (3) a medicao direta de fidelidade do S80 segue em revisao, como documentado no relatorio proprio do kernel.

PROPRIEDADE INTELECTUAL - AVISO LEGAL

O kernel **S160** (orquestrador completo) e marca registrada de Samuel Fernandes e propriedade intelectual exclusiva de **Samuel Ribeiro Fernandes**, com todos os direitos reservados, junto com toda a pilha IA Brasil, a interface IA-PRO e a ponte FUSION.

Nenhum codigo-fonte e divulgado neste documento: apenas comportamento observado e metricas medidas na maquina real. Este documento pode ser compartilhado integralmente para demonstracao, desde que sem alteracoes e mantendo este aviso. (c) 2026 Samuel Ribeiro Fernandes.